

# 多媒体技术课堂提问

## 1 特征脸(EigenFace)与PCA的关系

特征脸算法是基于主成分分析(PCA)的人脸识别方法。特征子脸技术的基本思想是：从统计的观点，寻找人脸图像分布的基本元素，即人脸图像样本集协方差矩阵的特征向量，以此近似地表征人脸图像。(总)

特征脸算法的基本步骤如下：

1. **构建样本集合**：获取包含有M张人脸图像的集合S，每张人脸图片的大小缩放到统一的尺寸，得到图像矩阵集合

$$S = \{\Gamma_1, \Gamma_2, \Gamma_3, \dots, \Gamma_M\}$$

2. **求得图像矩阵均值，也就是平均脸**：

$$mean = \frac{1}{M} \sum_{n=1}^M \Gamma_n$$

3. **图像矩阵零均值化**

$$\Phi_i = \Gamma_i - mean$$

4. **计算协方差矩阵及其特征值、特征向量**

$$\begin{aligned} C &= \frac{1}{M} \sum_{i=1, j=1}^M \Phi_i \Phi_j^T \\ &= AA^T \\ A &= \{\Phi_1, \Phi_2, \Phi_3, \dots, \Phi_n\} \end{aligned}$$

计算C的特征值 $\{\lambda_1, \lambda_2, \dots, \lambda_{N \times N}\}$ 与其对应的特征向量 $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{N \times N}\}$ 找到前n个特征值所对应的特征向量，组成新的矩阵V，由这些特征向量组成的新图像矩阵，也就是所谓的特征脸。

5. **进行人脸识别**

考虑一张新的人脸，缩放到相同的尺寸，然后进行特征转换，对应的公式为

$$\omega_k = u_k^T (\Gamma - mean)$$

其中 $k = 1, 2, \dots, M$ 表示对应的特征脸 $u_k$ ，也就是PCA中的第k个特征映射矢量，通过这M个特征脸，可以将新的人脸转变为在特征脸的坐标系的坐标表示。

$$\Omega^T = [\omega_1, \omega_2, \dots, \omega_M]$$

可以通过计算闵式距离，余弦夹角等指标判断新输入的图像和人脸库中图像的相似度。

## 2 求矩阵的特征值和特征向量

设A是n阶方阵，若存在数 $\lambda$ 和非零向量 $x$ 使得

$$Ax = \lambda x$$

则称 $\lambda$ 是A的特征值，非零向量 $x$ 是A的属于特征值 $\lambda$ 的特征向量。

$$\begin{aligned}
\lambda \text{ 为 } A \text{ 的特征值} &\Leftrightarrow Ax = \lambda x \\
&\Leftrightarrow \lambda x - Ax = 0 \\
&\Leftrightarrow (\lambda E - A)x = 0, x \neq 0 \\
&\Leftrightarrow (\lambda E - A)x = 0 \text{ 有非零解} \\
&\Leftrightarrow |\lambda E - A| = 0.
\end{aligned}$$

也就是说, 求解矩阵的特征值, 也就是求解  $|\lambda E - A| = 0$  的解

求属于  $\lambda$  的特征向量  $\Leftrightarrow$  求  $(\lambda E - A)x = 0$  的非零解向量.

例 3 求  $A = \begin{pmatrix} 1 & 2 & 2 \\ 2 & 1 & 2 \\ 2 & 2 & 1 \end{pmatrix}$  的全部特征值与特征向量.

【分析】求具体矩阵特征值及其特征向量, 一般通过解特征方程求解及方程组求解(具体步骤见上要点)

解  $A$  的特征方程为

$$\begin{aligned}
|A - \lambda E| &= \begin{vmatrix} 1-\lambda & 2 & 2 \\ 2 & 1-\lambda & 2 \\ 2 & 2 & 1-\lambda \end{vmatrix} = (5-\lambda) \begin{vmatrix} 1 & 2 & 2 \\ 1 & 1-\lambda & 2 \\ 1 & 2 & 1-\lambda \end{vmatrix} \\
&= (5-\lambda) \begin{vmatrix} 1 & 2 & 2 \\ 0 & -1-\lambda & 2 \\ 0 & 0 & -1-\lambda \end{vmatrix} = (5-\lambda)(1+\lambda)^2 = 0.
\end{aligned}$$

所以  $A$  的全部特征值为  $\lambda_1 = 5, \lambda_2 = \lambda_3 = -1$ .

$$\begin{aligned}
\text{当 } \lambda_1 = 5 \text{ 时, } A - 5E &= \begin{pmatrix} -4 & 2 & 2 \\ 2 & -4 & 2 \\ 2 & 2 & -4 \end{pmatrix} \sim \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & -1 \\ 0 & 0 & 0 \end{pmatrix}, \text{ 所以 } (A - 5E)x = 0 \text{ 可写成} \\
&\begin{cases} x_1 - x_2 = 0, \\ x_2 - x_3 = 0. \end{cases}
\end{aligned}$$

得基础解系为  $\xi_1 = (1, 1, 1)^T$ , 因此属于  $\lambda_1 = 5$  的全部特征向量为  $k_1 \xi_1$  ( $k_1 \neq 0$  的实数).

$$\text{当 } \lambda_2 = \lambda_3 = -1 \text{ 时, } A - E = \begin{pmatrix} 2 & 2 & 2 \\ 2 & 2 & 2 \\ 2 & 2 & 2 \end{pmatrix} \sim \begin{pmatrix} 1 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \text{ 所以 } (A - E)x = 0 \text{ 可写成}$$

$x_1 + x_2 + x_3 = 0$ , 得基础解系为  $\xi_2 = (-1, 1, 0)^T, \xi_3 = (-1, 0, 1)^T$ . 因此属于  $\lambda_2 = \lambda_3 = -1$  的全部特征向量为  $k_2 \xi_2 + k_3 \xi_3$  ( $k_2, k_3$  为不全零的实数).

【评注】 1.  $A$  中的  $\lambda_i$  对应线性无关的特征向量即为  $(\lambda_i E - A)x = 0$  基础解系;

2.  $A$  中  $\lambda_i$  对应线性无关的特征向量个数即为  $(\lambda_i E - A)x = 0$  基础解系所含向量个数的  $n - r(\lambda_i E - A)$ .

### 3 如何判断两个特征向量的正交性

设两个特征向量为 $a_1, a_2$

$$a_1 = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}, a_2 = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

向量正交即 $a_1^T a_2 = 0$

### 4 什么是矩阵的秩，请举例说明

矩阵A的秩是任意矩阵A经过行变换化成阶梯矩阵后,行的首元为1的个数。

### 5 如何构成训练样本的特征子空间（特征脸算法的特征子空间）

计算通过样本矩阵得到的协方差矩阵的特征值、特征向量

$$\begin{aligned} C &= \frac{1}{M} \sum_{i=1, j=1}^M \Phi_i \Phi_j^T \\ &= A A^T \\ A &= \{\Phi_1, \Phi_2, \Phi_3, \dots, \Phi_n\} \end{aligned}$$

计算C的特征值 $\{\lambda_1, \lambda_2, \dots, \lambda_{N \times N}\}$ 与其对应的特征向量 $\{v_1, v_2, \dots, v_{N \times N}\}$ 找到前n个最大特征值所对应的特征向量，组成新的矩阵V，这个矩阵V即特征子空间。

### 6 证明图像在经过直方均衡化后，图像的信息发生了丢失(或者说图像的信息熵减少了)

假设图像一共有 $k$ 个灰度级:  $0, 1, 2, \dots, k-1$ . 直方均衡过程中，每一个灰度级都被映射到新图像中的一个灰度级，把这个映射记为 $f: \{0, 1, 2, \dots, k-1\} \rightarrow \{0, 1, 2, \dots, k-1\}$ . 记原图像中对应频率不为0的灰度级的集合为 $S: S = \{x \in \{1, 2, \dots, k-1\} | \text{原图像中灰度级 } x \text{ 对应的频率不为 } 0\}$ . 现在将 $S$ 中的元素分为2类:

(1) 经过映射，只有这一个灰度级被映射到了对应的的灰度级。即灰度级 $x$ 满足:  $x \in S, f(x) = \hat{x}, \forall y \in S \text{ 且 } y \neq x, f(y) \neq \hat{x}$ . 显然，这个灰度级 $x$ 在原图中对 **信息熵** 的贡献，等于新图像中灰度级 $\hat{x}$ 对信息熵的贡献，均为 $-p_x \log(p_x)$ .

(2) 经过映射，这个灰度级和 $S$ 中若干个另外的灰度级，被映射到了新图像中的同一个灰度级。

假设 $s$ 个灰度级 $x_1, \dots, x_s$ 都被映射到新图像中的同一个灰度级 $y_0$ , 即:  $f(x_1) = f(x_2) = \dots = f(x_s) = y_0$ . 同时假设灰度级 $x_i$ 对应的频率为 $p_i$ .

考察这个过程里信息熵的变化:

原图中，对应这 $s$ 个灰度级的信息熵是 $H_1 = \sum_{i=1}^s p_i \log(\frac{1}{p_i})$ , 新图中对应灰度级 $y_0$ 的信息熵为 $H_2 = (\sum_{i=1}^s p_i) \log(\frac{1}{\sum_{i=1}^s p_i})$ .

$$\begin{aligned} H_1 - H_2 &= \sum_{i=1}^s p_i \log(\frac{1}{p_i}) - (\sum_{i=1}^s p_i) \log(\frac{1}{\sum_{i=1}^s p_i}) \\ &= \sum_{i=1}^s p_i [\log(\frac{1}{p_i}) - \log(\frac{1}{\sum_{i=1}^s p_i})] \\ &= \sum_{i=1}^s p_i \log(\frac{\sum_{i=1}^s p_i}{p_i}) > 0 \end{aligned}$$

这表明信息熵在直方均衡过程中有所损失。

## 7 证明协方差矩阵的三大性质

$$(1) \text{Cov}(Y, X) = \text{Cov}(X, Y)^T$$

$$\begin{aligned} & \text{Cov}(X, Y) \\ &= \frac{1}{m} \begin{bmatrix} (x_1 - E(x_1))(y_1 - E(y_1)) & \cdots & (x_1 - E(x_1))(y_n - E(y_n)) \\ (x_2 - E(x_2))(y_1 - E(y_1)) & \cdots & (x_2 - E(x_2))(y_n - E(y_n)) \\ \vdots & & \vdots \\ (x_n - E(x_n))(y_1 - E(y_1)) & \cdots & (x_n - E(x_n))(y_n - E(y_n)) \end{bmatrix} \\ &= \frac{1}{m} \begin{bmatrix} (x_1 - E(x_1)) \\ (x_2 - E(x_2)) \\ \vdots \\ (x_n - E(x_n)) \end{bmatrix} [y_1 - E(y_1), y_2 - E(y_2), \dots, y_n - E(y_n)] \\ &= E((\vec{X} - E(\vec{X}))(\vec{Y} - E(\vec{Y}))^T) \\ &\text{故 } \text{Cov}(Y, X) = E((\vec{Y} - E(\vec{Y}))(\vec{X} - E(\vec{X}))^T) \\ &= \text{Cov}(X, Y)^T \end{aligned}$$

$$(2) \text{Cov}(AX + b, Y) = A\text{Cov}(X, Y)$$

$$\begin{aligned} \text{Cov}(AX + b, Y) &= E((A\vec{X} + b - E(A\vec{X} + b))(\vec{Y} - E(\vec{Y}))^T) \\ &= E((A\vec{X} + b - E(A\vec{X}) - b)(\vec{Y} - E(\vec{Y}))^T) \\ &= E((A\vec{X} - AE(\vec{X}))(\vec{Y} - E(\vec{Y}))^T) \\ &= AE((\vec{X} - E(\vec{X}))(\vec{Y} - E(\vec{Y}))^T) \\ &= A\text{Cov}(X, Y) \end{aligned}$$

$$(3) \text{Cov}(X + Y, Z) = \text{Cov}(X, Z) + \text{Cov}(Y, Z)$$

$$\begin{aligned} \text{Cov}(X + Y, Z) &= E(((\vec{X} + \vec{Y}) - E(\vec{X} + \vec{Y}))(\vec{Z} - E(\vec{Z}))^T) \\ &= E(((\vec{X} + \vec{Y}) - E(\vec{X}) - E(\vec{Y}))(\vec{Z} - E(\vec{Z}))^T) \\ &= E((\vec{X} - E(\vec{X}))(\vec{Z} - E(\vec{Z}))^T) + E((\vec{Y} - E(\vec{Y}))(\vec{Z} - E(\vec{Z}))^T) \\ &= \text{Cov}(X, Z) + \text{Cov}(Y, Z) \end{aligned}$$

## 8 证明大津阈值法的类间方差公式

$$\begin{aligned} \sigma_B^2 &= w_0(\mu_0 - \mu_T)^2 + w_1(\mu_1 - \mu_T)^2 = w_0w_1(\mu_1 - \mu_0)^2 \\ \sigma_B^2 &= w_0(\mu_0 - \mu_T)^2 + w_1(\mu_1 - \mu_T)^2 \\ &= w_0(\mu_0 - w_0\mu_0 - w_1\mu_1)^2 + w_1(\mu_1 - w_0\mu_0 - w_1\mu_1)^2 \\ &= w_0(w_1\mu_0 - w_1\mu_1)^2 + w_1(w_0\mu_1 - w_0\mu_0)^2 \\ &= w_0w_1(\mu_1 - \mu_0)^2 \end{aligned}$$

## 9 傅里叶描述子基本公式的推导

我们首先假定物体的闭合边界曲线表示为一个总长度为 $N$ 的离散的坐标序列 $\{x(n), y(n) | n = 0, 1, \dots, N-1\}$ ，则它的复数形式表示为：

$$z(n) = x(n) + jy(n), n = 0, 1, \dots, N-1$$

这样这闭合曲线的边界就可以在一维空间上表示。由于闭合曲线的周期数为 $N$ （我们取了 $N$ 个点来表示闭合曲线），这一边界轮廓曲线的坐标序列也是周期的，周期长度为 $N$ 。

一维边界轮廓曲线坐标序列的傅里叶变换如下:

$$Z(k) = \sum_{n=0}^{N-1} z(n) \exp\left(-\frac{j2\pi kn}{N}\right), (0 \leq n \leq N-1)$$

坐标序列的逆变换为:

$$z(n) = \frac{1}{N} \sum_{k=0}^{N-1} Z(k) \exp\left(\frac{j2\pi kn}{N}\right), (0 \leq n \leq N-1)$$

$Z(k)$ 即为傅里叶描述子

## 10 证明归一化傅里叶描述子的三种不变性

归一化傅里叶描述子有三种不变性, 平移不变性、尺度不变性、旋转不变性。

先考虑旋转对傅里叶描述子的影响, 旋转后时域表达式为

$$z(n)' = e(j\alpha)z(n) \quad (1)$$

由离散傅里叶变换的线性性质, 变换后的 $Z(k)$ 为

$$Z(k)' = Z(k)e(j\alpha) \quad (2)$$

接着考虑尺度变换对傅里叶描述子的影响, 尺度变换后时域表达式为

$$z(n)'' = \lambda z(n) \quad (3)$$

由离散傅里叶变换的线性性质, 变换后的 $Z(k)$ 为

$$Z(k)'' = \lambda Z(k) \quad (4)$$

最后考虑平移对傅里叶描述子的影响, 平移后时域表达式为

$$z(n)''' = z(n) + z_0 \quad (5)$$

由离散傅里叶变换的线性性质, 变换后的 $Z(k)$ 为

$$Z(K)''' = \sum_{n=0}^{N-1} z(n) \exp\left(-\frac{j2\pi kn}{N}\right) + \sum_{n=0}^{N-1} z_0 \exp\left(-\frac{j2\pi kn}{N}\right) \quad (6)$$

当 $k$ 不为0时,  $\sum_{n=0}^{N-1} z_0 \exp\left(-\frac{j2\pi kn}{N}\right)$ 等于

$$\begin{aligned} \sum_{n=0}^{N-1} z_0 \exp\left(-\frac{j2\pi kn}{N}\right) &= z_0 \frac{1 - \exp\left(-\frac{j2kN\pi}{N}\right)}{1 - \exp\left(-\frac{j2k\pi}{N}\right)} \\ &= z_0 \frac{1 - \exp(-j2k\pi)}{1 - \exp\left(-\frac{j2k\pi}{N}\right)} \\ &= z_0 \frac{1 - \cos(2k\pi) - jsin(2k\pi)}{1 - \exp\left(-\frac{j2k\pi}{N}\right)} \\ &= z_0 \frac{1 - 1}{1 - \exp\left(-\frac{j2k\pi}{N}\right)} \\ &= 0 \end{aligned} \quad (7)$$

所以平移变换后傅里叶描述子只有 $Z(0)$ 发生变换

$$\sum_{n=0}^{N-1} z_0 \exp\left(-\frac{j2\pi kn}{N}\right) = \sum_{n=0}^{N-1} z_0 = Nz_0 \quad (8)$$

$$Z(0)''' = Z(0) + Nz_0 \quad (9)$$

归一化傅里叶描述子即去掉 $Z(0)$ 项，将 $Z(k)$ 除以 $Z(1)$

由于去掉 $Z(0)$ 项，显然具有尺度不变性。

由于旋转变换和尺度变换均满足

$$\frac{Z(k)'}{Z(1)'} = \frac{\alpha Z(k)}{\alpha Z(1)} = \frac{Z(k)}{Z(1)} \quad (10)$$

因此归一化傅里叶描述子满足尺度不变性和旋转不变性

**11 若 $A$ 是实矩阵，且 $AA^T$ 与 $A^T A$ 存在非零特征值。那么， $AA^T$ 与 $A^T A$ 的非零特征值相同，且对 $AA^T$ 的特征向量 $v$ ，必然存在 $A^T A$ 的一个特征向量 $v'$ ，满足关系：**

$$v = Av'$$

设 $\alpha$ 是 $AA^T$ 的特征值， $v$ 是 $AA^T$ 的特征向量，那么(1)式成立

$$AA^T v = \alpha v \quad (11)$$

设 $\beta$ 是 $A^T A$ 的特征值， $v'$ 是特征 $A^T A$ 的特征向量，那么(2)式成立

$$A^T A v' = \beta v' \quad (12)$$

对(2)式，左右两边同时乘以 $A$ ，可得

$$AA^T(Av') = \beta(Av') \quad (13)$$

故 $Av'$ 为 $AA^T$ 的一个特征向量， $\beta$ 为 $AA^T$ 的一个特征值。故得证

## 12 多媒体技术和人工智能的关系

一是多媒体促使人工智能向着更具可解释性的方向发展；

二是人工智能反过来为多媒体研究注入了新的思维方式，促进了多媒体技术推断能力的发展。

这两个方向形成了一个多媒体智能循环,其中多媒体和AI以交互和迭代的方式相互促进增强。

## 13 视觉知识的三要素

视觉知识的三要素包括视觉概念、视觉关系和视觉推理。